

UNIVERSITÉ PAUL VALÉRY

Département MIAHS

UFR 6 — Informatique, Mathématique et Statistique

CardioPredict

Prédiction du risque cardiovasculaire
par apprentissage automatique

Rapport de projet — Semestre 6

Cours : Science des données 4

Membres du groupe :

EL BASRI	Samy
ALI RACHEDI	Djibril
BOUSQUET	Arthur
BERETTI-PRENANT	Esteban

Résumé

Ce rapport présente le projet **CardioPredict**, réalisé dans le cadre du cours de Science des données 4 en Licence 3 MIASHS à l'Université Paul Valéry de Montpellier. L'objectif central est de fournir à toute personne un outil numérique simple, accessible et gratuit permettant d'obtenir une estimation de son risque cardiovasculaire à partir d'informations de santé basiques ou cliniques.

Deux jeux de données publics issus de Kaggle ont été sélectionnés : le dataset *Cardiovascular Disease* (70 000 observations) et le dataset *Heart Disease* (302 observations uniques après correction). Trois algorithmes de classification ont été comparés : régression logistique, arbre de décision et forêt aléatoire. Les modèles ont été évalués selon un protocole rigoureux incluant un split 80/20 stratifié et une validation croisée à 5 plis, afin de sélectionner le plus performant selon la métrique ROC-AUC. Le site web `cardio-predict.fr` a été déployé et est accessible publiquement.

Table des matières

1	Introduction	6
1.1	Contexte et motivation	6
1.2	Objectifs du projet	6
1.3	Dimension applicative et valeur ajoutée	7
1.4	Personas	8
2	Gestion de projet	9
2.1	Méthodologie	9
2.2	Outils de collaboration	9
2.2.1	GitHub	9
2.3	Contributions	9
2.3.1	Contribution par tâches	10
2.3.2	Contribution par pages du site	10
2.4	Planning	10
2.4.1	Diagramme de Gantt	11
3	Jeux de données et prétraitement	12
3.1	Présentation des datasets	12
3.1.1	Dataset Cardiovascular Disease (Cardio)	12
3.1.2	Dataset Heart Disease (Heart)	13
3.2	Analyse exploratoire	14
3.2.1	Distribution des classes	14
3.2.2	Observations notables	15
3.3	Prétraitement des données	15
3.3.1	Nettoyage du dataset Cardiovascular	15
3.3.2	Déduplication du dataset Heart — correction du data leakage	15
3.3.3	Pipeline de prétraitement	16
4	Modélisation et apprentissage automatique	17
4.1	Algorithmes comparés	17
4.2	Métriques d'évaluation	17
4.3	Résultats comparatifs	18
4.3.1	Dataset Cardiovascular	18

4.3.2	Dataset Heart	18
4.3.3	Visualisations des performances	19
4.4	Analyse des modèles retenus	19
4.4.1	Importance des variables	19
4.4.2	Matrices de confusion	20
4.4.3	Courbes ROC	20
5	Site web — Description fonctionnelle	21
5.1	Technologies utilisées	21
5.2	Architecture de l'application	21
5.3	Description des pages	21
5.3.1	Page d'accueil — <code>index.php</code>	22
5.3.2	Page prédiction — Test classique (<code>prediction.php?mode=cardio</code>)	23
5.3.3	Page prédiction — Test avancé (<code>prediction.php?mode=heart</code>)	24
5.3.4	Panneau de résultat	25
5.3.5	Page visualisations (<code>visualisations.php</code>)	26
5.3.6	Page méthode (<code>methode.php</code>)	27
6	Déploiement	28
6.1	Hébergement choisi	28
6.2	Diagnostic de l'environnement	28
6.3	Solution technique : modèles exportés en JSON	28
7	Conclusions et perspectives	30
7.1	Bilan du projet	30
7.2	Difficultés rencontrées	30
7.2.1	Data leakage sur le dataset Heart	30
7.2.2	Expression de l'âge en jours	31
7.2.3	Renormalisation des valeurs des arbres de décision	31
7.3	Perspectives à long terme	31
A	Structure du projet	33
B	Tableau complet des métriques	34

Table des figures

1.1	Personas utilisateurs de CardioPredict	8
2.1	Diagramme de Gantt du projet CardioPredict	11
3.1	Distribution de la variable cible dans les deux datasets	14
4.1	Comparaison des trois modeles sur les deux datasets	19
4.2	Importance des variables dans les deux modeles retenus	19
4.3	Matrices de confusion des modeles retenus (ensemble de test)	20
4.4	Courbes ROC des trois modeles compares sur chaque dataset	20
5.1	Page d'accueil de CardioPredict	22
5.2	Page de prediction — mode Test classique (dataset Cardio)	23
5.3	Page de prediction — mode Test avance (dataset Heart)	24
5.4	Panneau de résultat apres une prediction (mode classique)	25
5.5	Page des visualisations avec systeme d'onglets	26
5.6	Page méthode presentant les 6 etapes du projet	27

Liste des tableaux

2.1	Contribution par taches (en pourcentage)	10
2.2	Contribution par page du site web	10
3.1	Variables du dataset Cardiovascular (apres pretraitement)	13
3.2	Variables du dataset Heart (apres pretraitement)	14
3.3	Tailles des ensembles train / test	16
4.1	Resultats — Dataset Cardiovascular (14 000 obs. de test)	18
4.2	Resultats — Dataset Heart (61 obs. de test, apres deduplication)	18
B.1	Metriques completes pour tous les modeles testes	34

Chapitre 1

Introduction

1.1 Contexte et motivation

Les maladies cardiovasculaires représentent la première cause de mortalité mondiale selon l'Organisation Mondiale de la Santé (OMS), responsables de près de 18 millions de décès chaque année. En France, elles touchent plus de 17 millions de personnes et constituent un enjeu de santé publique majeur. Pourtant, une grande partie de la population ignore les facteurs de risque qui la concernent directement : hypertension artérielle, sédentarité, alimentation, tabagisme ou encore prédispositions génétiques.

Dans ce contexte, l'accès à une information claire, rapide et personnalisée sur son propre risque cardiovasculaire peut jouer un rôle clé dans la prévention. Or les outils existants sont soit trop techniques pour le grand public, soit réservés aux professionnels de santé, soit accessibles uniquement lors d'une consultation médicale. Il existe donc un véritable manque d'outils numériques accessibles, gratuits et pédagogiques permettant à n'importe qui d'évaluer simplement son profil de risque.

1.2 Objectifs du projet

CardioPredict est né de ce constat. Notre ambition est de concevoir une **plateforme web spécialisée, gratuite et facile d'accès**, destinée à toute personne souhaitant obtenir une estimation de son risque cardiovasculaire — que ce soit par simple curiosité, dans une démarche de prévention, ou en complément d'un suivi médical.

Les objectifs concrets du projet sont les suivants :

1. **Rendre le diagnostic accessible à tous** : proposer deux niveaux d'analyse. Le premier, appelé «Test classique», ne nécessite aucune donnée médicale détaillée et peut être rempli par n'importe qui en moins de deux minutes (âge, poids, tension approximative, habitudes de vie). Le second, le «Test avancé», s'adresse aux personnes disposant d'un bilan cardiologique et offre une estimation plus précise ;

2. **S'appuyer sur des données réelles et des méthodes scientifiques** : les modèles de prédiction sont entraînés sur des jeux de données cliniques publics et évalués rigoureusement selon des métriques standard (ROC-AUC, accuracy, F1-Score);
3. **Etre transparent et pédagogique** : le site présente la méthode, les visualisations, les performances des modèles et leurs limites. L'utilisateur sait sur quoi repose l'estimation qu'il reçoit;
4. **Mettre en garde sans alarmer** : le site fournit un **indicateur de risque**, non un diagnostic médical. Un avertissement clair rappelle que l'outil ne remplace en aucun cas une consultation avec un professionnel de santé;
5. **Deployer un service en ligne opérationnel** : le site est hébergé et accessible publiquement à l'adresse <https://cardio-predict.fr>.

1.3 Dimension applicative et valeur ajoutée

Au-delà de l'aspect académique, CardioPredict possède une véritable valeur d'usage. Dans une logique de santé numérique en plein essor, un tel outil pourrait s'inscrire dans plusieurs scénarios concrets :

- **Prévention individuelle** : une personne de 50 ans, sédentaire et légèrement en surpoids, peut consulter le site, obtenir un niveau de risque «modéré» et être incitée à consulter un médecin ou à modifier ses habitudes de vie;
- **Support pédagogique** : des enseignants ou formateurs en santé publique pourraient utiliser l'outil pour illustrer concrètement les facteurs de risque cardiovasculaire;

1.4 Personas



FIGURE 1.1 – Personas utilisateurs de CardioPredict

Chapitre 2

Gestion de projet

2.1 Méthodologie

Ce projet a été conduit selon une approche **agile**. Plutôt que de définir un cahier des charges figé, nous avons organisé notre travail en itérations successives, chaque semaine permettant de valider un sous-ensemble de fonctionnalités et d'adapter nos priorités en fonction des difficultés rencontrées.

2.2 Outils de collaboration

2.2.1 GitHub

Le dépôt GitHub du projet est disponible à l'adresse : <https://github.com/samy954/projet-ml-cardiovasculaire>

Nous avons utilisé Git avec les pratiques suivantes :

- Avoir un espace de dépôt en ligne accessible à tout moment permettant de travailler de manière autonome
- Le fichier `.gitignore` exclut les fichiers volumineux (`*.csv`, `*.joblib`), les caches Python (`__pycache__`/) et les configurations locales;
- L'historique des commits a été consulté pour récupérer d'anciennes versions du script de prédiction lors du débogage.

2.3 Contributions

2.3.1 Contribution par tâches

TABLE 2.1 – Contribution par taches (en pourcentage)

Tache	El Basri	Ali Rachedi	Bousquet	Beretti-P.
Selection et analyse des datasets	40%	20%	20%	20%
Exploration et visualisations	50%	20%	20%	10%
Pretraitement des donnees	40%	20%	20%	20%
Modelisation et entraînement	50%	20%	15%	15%
Correction data leakage	60%	10%	20%	10%
Developpement site web (PHP/CSS)	40%	15%	20%	25%
Integration modeles dans le site	60%	15%	15%	10%
Deploiement IONOS	50%	10%	20%	20%
Redaction du rapport	50%	20%	15%	15%
Tests et validation	30%	25%	25%	20%

2.3.2 Contribution par pages du site

TABLE 2.2 – Contribution par page du site web

Page / Fichier	El Basri	Ali Rachedi	Bousquet	Beretti-P.
index.php	40%	20%	20%	20%
prediction.php	60%	0%	30%	10%
visualisations.php	40%	20%	20%	20%
methode.php	30%	15%	10%	45%
ml/predict.py	70%	10%	10%	10%
assets/css/style.css	0%	80%	20%	0%
Visualisations Python	50%	15%	10%	25%

2.4 Planning

2.4.1 Diagramme de Gantt




FIGURE 2.1 – Diagramme de Gantt du projet CardioPredict

Chapitre 3

Jeux de données et prétraitement

3.1 Présentation des datasets

3.1.1 Dataset Cardiovascular Disease (Cardio)

Source

Kaggle — Sulianova, *Cardiovascular Disease Dataset*
[https://www.kaggle.com/datasets/sulianova/
cardiovascular-disease-dataset](https://www.kaggle.com/datasets/sulianova/cardiovascular-disease-dataset)

Ce dataset contient des informations médicales anonymisées collectées lors d'exams cliniques. Il se compose de **70 000 observations** et 13 colonnes dans sa version brute. Le fichier est au format CSV (séparateur ;) et pèse environ 3 Mo.

TABLE 3.1 – Variables du dataset Cardiovascular (apres pretraitement)

Variable	Type	Signification	Valeurs
age	Entier	Age en jours	10 798–23 713
gender	Binaire	Genre	1=Femme, 2=Homme
height	Entier	Taille (cm)	55–250
weight	Decimal	Poids (kg)	10–200
ap_hi	Entier	Pression systolique	60–250 mmHg
ap_lo	Entier	Pression diastolique	40–180 mmHg
cholesterol	Ordinal	Niveau de cholesterol	1/2/3
gluc	Ordinal	Niveau de glucose	1/2/3
smoke	Binaire	Tabagisme	0=Non, 1=Oui
alco	Binaire	Consommation d'alcool	0=Non, 1=Oui
active	Binaire	Activite physique	0=Non, 1=Oui
cardio	Binaire	Variable cible	0=Sain, 1=Malade

3.1.2 Dataset Heart Disease (Heart)

Source

Kaggle — johnsmith88, *Heart Disease Dataset*

<https://www.kaggle.com/datasets/johnsmith88/heart-disease-dataset>

Ce dataset est la concatenation de quatre bases de donnees cliniques historiques (Cleveland, Hungarian, Suisse, VA Long Beach) issues du depot UCI. Il contient des variables cliniques precises issues de bilans cardiologiques.

Les deux datasets presentent un equilibre satisfaisant : environ 50/50 pour le dataset Cardiovascular et 54/46 pour le dataset Heart apres deduplication. Aucun reequilibrage artificiel n'a donc ete necessaire.

3.2.2 Observations notables

Pour le dataset Cardiovascular :

- L'âge est exprimé en jours dans le dataset brut (entre 10 798 et 23 713 jours, soit 29 à 65 ans environ);
- La colonne `weight` utilise parfois la virgule comme séparateur décimal, nécessitant une correction automatique;

3.3 Prétraitement des données

3.3.1 Nettoyage du dataset Cardiovascular

1. Suppression des colonnes d'identifiant (`id`, `dataset_id`);
2. Correction des décimales (virgule vers point) sur `weight`;
3. Sélection des 11 variables pertinentes listées dans le tableau 3.1.

3.3.2 Déduplication du dataset Heart — correction du data leakage

Probleme critique : data leakage par doublons

Le dataset Heart brut contient **723 lignes dupliques sur 1 025** (70,5% du dataset). Ce phenomene provient de la concatenation de quatre bases de donnees sources partageant de nombreuses observations identiques. Sans deduplication, les memes observations se retrouvent simultanement dans le train et le test, gonflant artificiellement les metriques jusqu'a des valeurs parfaites (accuracy = 1,0, ROC-AUC = 1,0) qui ne reflektent aucune capacite de generalisation reelle.

Etapes appliquees :

1. Suppression des colonnes parasites (`id_heart`, `cardio_id`, `dataset_id`);
2. Correction des decimales;
3. Deduplication : le dataset passe de 1 025 a **302 observations uniques**;
4. Verification : apres split 80/20, aucune observation du test n'est presente dans le train.

3.3.3 Pipeline de prétraitement

Les données sont préparées via un pipeline en deux étapes appliqué avant tout entraînement : imputation des valeurs manquantes par la médiane, puis standardisation par centrage-réduction (soustraction de la moyenne, division par l'écart-type). La graine aléatoire est fixée à 42 pour la reproductibilité des résultats.

TABLE 3.3 – Tailles des ensembles train / test

Dataset	Total	Train (80%)	Test (20%)
Cardiovascular	70 000	56 000	14 000
Heart	302	241	61

Chapitre 4

Modélisation et apprentissage automatique

4.1 Algorithmes comparés

Trois algorithmes de classification supervisée ont été comparés sur chaque dataset :

Regression Logistique Modele lineaire, tres interpretable, regularisation L2 par default. Parametre : `max_iter=1000`.

Arbre de Decision Modele non-lineaire, profondeur limitee (`max_depth=6` pour Cardio, `max_depth=5` pour Heart) pour eviter le surapprentissage.

Forêt Aleatoire Methode d'ensemble combinant 200 arbres. `n_estimators=200`, `max_depth=10` (Cardio) ou 6 (Heart).

4.2 Métriques d'évaluation

Le critere principal de selection est la **ROC-AUC**, car elle mesure la capacite de discrimination independamment du seuil de decision et est bien adaptee au contexte medical. En cas d'egalite, le F1-Score sert de critere secondaire.

Les modeles ont été évalués selon deux protocoles complementaires :

- **Split 80/20 stratifie** : separation des donnees en ensemble d'entrainement (80%) et ensemble de test (20%), avec stratification sur la variable cible pour garantir une proportion identique de classes dans chaque ensemble ;
- **Validation croisee a 5 plis** : les donnees d'entrainement sont divisees en 5 sous-ensembles, le modele est entraine 5 fois en utilisant successivement chacun comme ensemble de validation. Cette methode fournit des estimations de performance plus robustes et moins sensibles au tirage aleatoire initial.

Les autres metriques calculees sont l'accuracy, la precision, le rappel et le F1-Score. En contexte medical, le rappel (minimiser les faux negatifs, c'est-a-dire les malades non detectes) est particulierement important.

4.3 Résultats comparatifs

4.3.1 Dataset Cardiovascular

TABLE 4.1 – Resultats — Dataset Cardiovascular (14 000 obs. de test)

Modele	Accuracy	Precision	Rappel	F1	ROC-AUC
Regression Logistique	0,714	–	–	–	0,778
Arbre de Decision	0,728	–	–	–	0,790
Foret Aleatoire	0,732	0,756	0,684	0,718	0,798

La foret aleatoire est retenue avec une ROC-AUC de 0,798. La grande taille du dataset (70 000 observations) favorise les methodes d'ensemble.

4.3.2 Dataset Heart

TABLE 4.2 – Resultats — Dataset Heart (61 obs. de test, apres deduplication)

Modele	Accuracy	Precision	Rappel	F1	ROC-AUC
Regression Logistique	0,803	0,800	0,848	0,824	0,871
Foret Aleatoire	0,770	–	–	0,788	0,862
Arbre de Decision	0,770	–	–	0,781	0,832

Sur le dataset Heart, la regression logistique surpasse la foret aleatoire. Avec seulement 302 observations, un modele simple et regularise generalise mieux qu'une methode d'ensemble qui dispose de trop peu d'exemples pour construire des arbres diversifies.

4.3.3 Visualisations des performances




FIGURE 4.1 – Comparaison des trois modeles sur les deux datasets

4.4 Analyse des modèles retenus

4.4.1 Importance des variables





FIGURE 4.2 – Importance des variables dans les deux modeles retenus

Pour le dataset Cardiovasculaire, la **pression systolique**, l'**âge** et le **poids** sont les variables les plus discriminantes, ce qui est parfaitement coherent avec la litterature medecale sur les facteurs de risque cardiovasculaire.

Pour le dataset Heart, le **type de douleur thoracique**, le **nombre de vaisseaux colores** et la **frequence cardiaque maximale** ressortent comme les plus determinants — des resultats alignes avec les connaissances cardiologiques.

4.4.2 Matrices de confusion




(a) Random Forest — Cardio

(b) Regression Logistique — Heart

FIGURE 4.3 – Matrices de confusion des modeles retenus (ensemble de test)

4.4.3 Courbes ROC



(a) Dataset Cardiovascular

(b) Dataset Heart (apres deduplication)

FIGURE 4.4 – Courbes ROC des trois modeles compares sur chaque dataset

Toutes les courbes sont nettement au-dessus de la diagonale (classifieur aleatoire), confirmant que les modeles ont bien capture des patterns predictifs dans les donnees.

Chapitre 5

Site web — Description fonctionnelle

5.1 Technologies utilisées

- **PHP 8.4** : logique serveur, gestion des formulaires, appel du script Python;
- **Python 3.11** : execution des predictions via `ml/predict.py`;
- **HTML5 / CSS3** : structure et style des pages;
- **JSON** : format d'échange entre PHP et Python en production;
- **matplotlib, seaborn** : generation des visualisations;
- **Git / GitHub** : gestion de versions et collaboration.

5.2 Architecture de l'application

Lors d'une prediction, le flux de donnees est le suivant :

1. L'utilisateur remplit le formulaire et soumet ses donnees (HTTP POST);
2. PHP ecrit les valeurs dans un fichier JSON temporaire;
3. PHP appelle `predict.py` via `shell_exec()`;
4. Python charge le modele (fichier JSON), pretraite les donnees, calcule la probabilite et retourne un objet JSON;
5. PHP desserialise la reponse et affiche le resultat.

5.3 Description des pages

5.3.1 Page d'accueil — `index.php`




FIGURE 5.1 – Page d'accueil de CardioPredict

La page d'accueil constitue la vitrine du projet. Elle s'articule autour de plusieurs éléments :

- **En-tête hero** : accroche principale avec le titre du projet, une description synthétique et deux boutons d'appel à l'action («Tester une prediction» et «Voir les visualisations»);
- **Stats boxes** : trois indicateurs clés mis en avant — le nombre total d'observations utilisées (70 000 + 302), le nombre de modèles comparés (3), et la meilleure ROC-AUC obtenue (0,87);
- **Deux cartes datasets** : une carte par dataset (Cardio et Heart) présentant les caractéristiques principales et le modèle retenu, avec un bouton direct vers la prédiction correspondante;
- **Section data leakage** : encadre explicatif sur le problème de doublons détecté et corrigé sur le dataset Heart.

La navigation est assurée par une barre fixe en haut de page (Accueil, Prédiction, Visualisations, Méthode).

5.3.2 Page prédiction — Test classique (`prediction.php?mode=cardio`)

Test classique

Dataset cardio (70 000 observations)

Variables générales, faciles à renseigner sans données médicales détaillées.

Accessible sans bilan médical détaillé. L'âge est saisi en années — la conversion en jours (unité du dataset) est faite automatiquement.

Ce mode utilise le dataset cardio (Kaggle – Cardiovascular Disease). Il demande des données générales : âge, taille, poids, tension, cholestérol et habitudes de vie. Le modèle retenu est un Random Forest (ROC-AUC $\approx 0,80$).

Âge (en années) **Genre**

Exemple : 50 Femme

Taille (cm) **Poids (kg)**

Exemple : 170 Exemple : 70

Pression systolique (mmHg) **Pression diastolique (mmHg)**

Exemple : 120 Exemple : 80

Cholestérol **Glycémie**

Normal Normale

Fumeur-se **Consommation d'alcool**

Non Non

Résultat du modèle

Le résultat affiché correspond au modèle sélectionné ci-dessus.

Aucun résultat pour le moment.

Choisis un mode, remplis le formulaire, puis lance la prédiction pour afficher l'estimation du modèle.

FIGURE 5.2 – Page de prediction — mode Test classique (dataset Cardio)

Le **Test classique** est conçu pour être accessible à tout utilisateur sans connaissance médicale préalable. Le formulaire demande 11 informations :

- **Age** (en années — la conversion en jours est effectuée automatiquement côté serveur, car le dataset stocke l'âge en jours) ;
- **Genre, Taille, Poids** ;
- **Pressions systolique et diastolique** avec exemples indicatifs ;
- **Niveau de cholestérol et de glycémie** (3 niveaux : Normal / Au-dessus / Bien au-dessus) avec infobulles explicatives (icône ?) ;
- **Tabagisme, alcool, activité physique** (listes déroulantes Oui/Non).

Le panneau de droite affiche l'état «Aucun résultat pour le moment» tant que le formulaire n'a pas été soumis.

5.3.3 Page prédiction — Test avancé (prediction.php?mode=heart)

Dataset heart (302 observations uniques)

Variables cliniques précises — nécessite un bilan médical.

Données issues d'un bilan cardiologique requis. Le dataset a été dédoublé (723 doublons supprimés sur 1025 lignes) pour garantir des métriques fiables.

Ce mode utilise le dataset heart (Kaggle – Heart Disease). Il demande des variables cliniques détaillées comme le type de douleur thoracique, l'ECG ou la fréquence cardiaque maximale. Le modèle retenu est une Régression Logistique (ROC-AUC $\approx 0,87$).

Âge (en années) : Exemple : 54

Sexe : Homme

Type de douleur thoracique : Angine typique

Pression artérielle au repos (mmHg) : Exemple : 130

Cholestérol sérique (mg/dL) : Exemple : 246

Glycémie à jeun > 120 mg/dL : Non

Résultat ECG au repos : Normal

Fréquence cardiaque maximale atteinte : Exemple : 150

Angine induite par l'effort : Non

Oldpeak (dépression ST) : Exemple : 1.2

Pente du segment ST à l'effort

Nombre de vaisseaux colorés (0–3)

Résultat du modèle

Le résultat affiché correspond au modèle sélectionné ci-dessus.

Aucun résultat pour le moment.

Choisis un mode, remplis le formulaire, puis lance la prédiction pour afficher l'estimation du modèle.

FIGURE 5.3 – Page de prediction — mode Test avance (dataset Heart)

Le **Test avance** s'adresse aux personnes disposant d'un bilan cardiologique complet. Il demande 13 variables cliniques précises :

- **Age, Sexe** ;
- **Type de douleur thoracique** (angine typique, atypique, non angineuse, asymp-tomatique) ;
- **Pression artérielle au repos, Cholesterol serique, Glycemie a jeun** ;
- **Resultat ECG au repos** (Normal, Anomalie ST-T, Hypertrophie ventriculaire) ;
- **Frequence cardiaque maximale, Angine a l'effort, Oldpeak** (depression ST), **Pente du segment ST, Nombre de vaisseaux colores, Thalassemie**.

Chaque champ medical complexe dispose d'une **infobulle** (icone ?) qui s'affiche au survol et explique en termes accessibles ce que le champ represente. Une notice rappelle que ce mode necessite un bilan medical et que le dataset a été deduplique pour garantir des metriques fiables.

5.3.4 Panneau de résultat




FIGURE 5.4 – Panneau de résultat après une prediction (mode classique)

Après soumission du formulaire, le panneau de droite affiche :

- Le **type de test** et le **jeu de donnees** utilise;
- Le **niveau de risque** (Faible / Modere / Eleve) avec code couleur;
- La **probabilite estimee** en pourcentage (ici 46,5%);
- La **prediction binaire** et son libelle («Risque cardiovasculaire non detecte» dans cet exemple);

- Un **message contextuel** et un **avertissement medical** rappelant que la prediction ne remplace pas un avis professionnel ;
- Un **tableau de metriques** : modele utilise (Random Forest), accuracy (0,7319), ROC-AUC (0,7983), F1-Score, precision, rappel, tailles du train et du test.

5.3.5 Page visualisations (`visualisations.php`)




FIGURE 5.5 – Page des visualisations avec systeme d'onglets

La page visualisations regroupe l'ensemble des graphiques du projet, organisés en trois onglets JavaScript :

- **Onglet «Dataset Cardio»** : repartition de la cible, importance des variables, matrice de confusion, courbe ROC — chaque graphique est accompagné d'une observation commentée dans un encadré bleu ;
- **Onglet «Dataset Heart»** : mêmes graphiques pour le dataset Heart, avec explication du problème de doublons et de la deduplication ;
- **Onglet «Comparaison des modèles»** : graphique comparatif Accuracy / ROC-AUC / F1-Score pour les trois algorithmes sur les deux datasets.

5.3.6 Page méthode (methode.php)




FIGURE 5.6 – Page méthode présentant les 6 étapes du projet

La page methode presente la demarche scientifique en **6 étapes numérotées** : sélection des datasets, analyse exploratoire, pretraitement (avec mention explicite de la deduplication du dataset Heart), split train/test, modeles testes, et critere de selection. Chaque etape est presentee dans une carte illustree.

Un tableau comparatif des resultats des trois modeles sur les deux datasets complete la page, avec mise en evidence du modele retenu pour chaque dataset.

Chapitre 6

Déploiement

6.1 Hébergement choisi

Le site est hébergé sur **IONOS** (offre Hébergement Web Standard) avec le nom de domaine `cardio-predict.fr`. IONOS a été retenu car il propose PHP nativement, un accès SSH et Python 3.11 préinstallé.

6.2 Diagnostic de l'environnement

Avant tout upload, l'environnement a été diagnostiqué via des scripts PHP de test :

- PHP 8.4.18, `disable_functions = no value` (`shell_exec` autorisé);
- Python 3.11.2 disponible à `/usr/bin/python3`;
- Bibliothèques Python tierces (numpy, pandas, etc.) **non disponibles** en raison des restrictions système de l'hébergement mutualisé.

6.3 Solution technique : modèles exportés en JSON

Afin de contourner l'impossibilité d'installer des bibliothèques Python tierces sur le serveur de production, nous avons adopté une solution originale : **exporter les modèles entraînés en JSON et les réimplémenter en Python standard** (sans aucune dépendance externe).

Les paramètres de la forêt aléatoire (structure de chaque arbre : nœuds, seuils, valeurs des feuilles) et de la régression logistique (coefficients, intercept, médiane, moyenne, écart-type du scaler) sont extraits lors de la phase d'entraînement locale et serialisés en fichiers JSON. En production, Python relit ces fichiers et effectue les calculs avec uniquement les modules standards `json` et `math`.

Validation : les prédictions du modèle JSON ont été comparées à celles obtenues lors de l'entraînement sur 500 observations (Cardio) et 302 (Heart).

Resultats de validation :

- Forêt Aleatoire (Cardio) : **500/500 predictions identiques**
- Regression Logistique (Heart) : **302/302 predictions identiques**
- Difference maximale de probabilite : $< 0,007$ (ecart de virgule flottante)

Chapitre 7

Conclusions et perspectives

7.1 Bilan du projet

Le projet CardioPredict a permis de mener a bien l'ensemble du cycle d'un projet de science des donnees : collecte et nettoyage des donnees, analyse exploratoire, comparaison de modeles, developpement web et deploiement en production. Les principaux apports sont :

- **Scientifique** : deux modeles de prediction cardiovasculaire ont été construits et evalues avec des metriques rigoureuses (ROC-AUC 0,798 et 0,871);
- **Methodologique** : la detection et correction du data leakage sur le dataset Heart illustre l'importance de l'audit critique des donnees;
- **Technique** : la reimplementation des modeles en Python standard est une solution originale aux contraintes d'hebergement;
- **Applicatif** : le site est deploye et accessible publiquement a l'adresse <http://cardio-predict.fr>.

7.2 Difficultés rencontrées

Tout au long du projet, nous avons ete confrontes a de nombreuses difficultes techniques et organisationnelles.

7.2.1 Data leakage sur le dataset Heart

La decouverte que 723 lignes sur 1 025 etaient identiques dans le dataset Heart a ete un impreuv majeur. Sans cette verification, notre modele aurait affiche une ROC-AUC parfaite de 1,0 sur le test set — un resultat aberrant qui nous a immediatement alerte. Identifier la cause (concatenation de quatre sources UCI avec des observations communes) et y remedier (deduplication systematique) a demande plusieurs jours d'investigation et de tests de validation.

7.2.2 Expression de l'âge en jours

Le dataset Cardiovascular stocke l'âge en jours (et non en années), ce qui était peu intuitif pour les utilisateurs du formulaire. Il a fallu modifier la logique pour accepter la saisie en années côté interface et effectuer la conversion ($\text{jours} = \text{années} \times 365,25$) côté Python, de façon transparente.

7.2.3 Renormalisation des valeurs des arbres de décision

Lors de l'export JSON de la forêt aléatoire, un bug subtil avait converti les valeurs des feuilles des arbres (`float`) en `int` via une troncature involontaire (ex. : 0,498 converti en 0), ce qui rendait toutes les probabilités identiques (50%). Ce bug a été détecté lors de la phase de validation par comparaison systématique des prédictions obtenues, et corrigé en conservant les valeurs en virgule flottante.

7.3 Perspectives à long terme

- **Enrichissement des données** : intégrer des variables complémentaires (antécédents familiaux, taux de triglycérides, sédentarité détaillée) pour améliorer la robustesse des modèles ;
- **Interface professionnelle** : gestion de comptes, historique des prédictions, export PDF, API REST pour intégration dans des logiciels médicaux ;.

Site web du projet

<http://cardio-predict.fr>

Code source disponible sur GitHub.

Bibliographie

- [1] Sulianova (2019). *Cardiovascular Disease Dataset*. Kaggle. <https://www.kaggle.com/datasets/sulianova/cardiovascular-disease-dataset>
- [2] johnsmith88 (2019). *Heart Disease Dataset*. Kaggle. <https://www.kaggle.com/datasets/johnsmith88/heart-disease-dataset>
- [3] Janosi A., Steinbrunn W., Pfisterer M., Detrano R. (1988). *Heart Disease Data Set*. UCI Machine Learning Repository.
- [4] Breiman L. (2001). *Random Forests*. *Machine Learning*, 45(1), 5–32.
- [5] Hosmer D.W., Lemeshow S. (2000). *Applied Logistic Regression* (2nd ed.). Wiley.
- [6] OMS (2021). *Maladies cardiovasculaires*. <https://www.who.int/fr/news-room/fact-sheets/detail/cardiovascular-diseases>
- [7] Fawcett T. (2006). *An Introduction to ROC Analysis*. *Pattern Recognition Letters*, 27(8), 861–874.

Annexe A

Structure du projet

```
cardiopredict/
|-- index.php                Page d'accueil
|-- prediction.php          Page de prediction
|-- visualisations.php      Page des graphiques
|-- methode.php             Page de methodologie
|-- partials_header.php     En-tete commun
|-- partials_footer.php     Pied de page commun
|-- assets/
|   |-- css/style.css       Feuille de style
|   |-- js/app.js           Scripts JavaScript
|   `-- img/               Graphiques Python
|-- ml/
|   |-- predict.py          Script de prediction (Python pur)
|   |-- models/
|       |-- cardio_model.json  Foret aleatoire exportee en JSON
|       `-- heart_model.json   Regression logistique en JSON
|   `-- metadata/
|       |-- cardio_model_info.json
|       `-- heart_model_info.json
|-- data/
|   |-- cardio.csv          Dataset Cardiovascular
|   |-- heart.csv           Dataset Heart
|   `-- README.txt
`-- tmp/                   Fichiers JSON temporaires
```

Annexe B

Tableau complet des métriques

TABLE B.1 – Metriques completes pour tous les modeles testes

Dataset	Modele	Acc.	Prec.	Rappel	F1	AUC
Cardio	Reg. Logistique	0,714	–	–	–	0,778
	Arbre de Decision	0,728	–	–	–	0,790
	Foret Aleat.	0,732	0,756	0,684	0,718	0,798
Heart	Reg. Logistique	0,803	0,800	0,848	0,824	0,871
	Foret Aleat.	0,770	–	–	0,788	0,862
	Arbre de Decision	0,770	–	–	0,781	0,832