

UNIVERSITÉ PAUL VALÉRY – Montpellier 3

Département MIASHS – UFR 6

CardioPredict

Prédiction et suivi du risque cardiovasculaire

par apprentissage automatique

Rapport final amélioré – Projet de Science des données 4 – Semestre 6

Membres du groupe : EL BASRI Samy

ALI RACHEDI Djibril

BOUSQUET Arthur

BERETTI-PRENANT Esteban

Cours : Science des données 4

Projet : Application web de machine learning appliquée à la santé

Année universitaire 2025–2026

Résumé

Ce rapport présente la version finale améliorée du projet **CardioPredict**, réalisé dans le cadre du cours de Science des données 4 en Licence 3 MIASHS. L'objectif initial du projet était de développer une application web capable d'estimer le risque cardiovasculaire d'un utilisateur à partir de données de santé simples ou cliniques. Deux jeux de données publics ont été utilisés : le dataset *Cardiovascular Disease*, composé de 70 000 observations, et le dataset *Heart Disease*, réduit à 302 observations uniques après déduplication.

La première version du projet couvrait déjà les principales étapes d'un projet de science des données : sélection des datasets, nettoyage, analyse exploratoire, entraînement de modèles, comparaison des performances, intégration dans un site PHP/Python et déploiement. Les modèles retenus étaient une forêt aléatoire pour le dataset Cardio et une régression logistique pour le dataset Heart, avec une sélection fondée principalement sur la ROC-AUC.

La version améliorée renforce le projet sur trois dimensions majeures. Premièrement, une vraie base de données MySQL a été ajoutée afin de stocker les comptes utilisateurs et les historiques. Deuxièmement, le site a été transformé en plateforme de suivi santé avec un espace utilisateur, un dashboard, un historique des prédictions, un calculateur d'IMC, un calculateur calorique et une page d'analyse de la tension artérielle. Troisièmement, l'évaluation machine learning a été approfondie avec des métriques médicales, une analyse des faux négatifs, une optimisation des seuils, une recherche d'hyperparamètres et une meilleure étude des valeurs aberrantes.

Le projet final ne se limite donc plus à un formulaire de prédiction. Il devient une application web pédagogique plus complète, combinant machine learning, base de données, visualisations, espace personnel et outils de prévention cardiovasculaire. Un avertissement médical rappelle néanmoins que les résultats fournis sont des estimations statistiques et ne remplacent pas un diagnostic professionnel.

Table des matières

1	Introduction	1
1.1	Contexte et motivation	1
1.2	Objectifs du projet	1
1.3	Valeur ajoutée de la version améliorée	2
1.4	Publics visés	2
2	Gestion de projet	3
2.1	Méthodologie de travail	3
2.2	Outils utilisés	3
2.3	Répartition des contributions	4
2.4	Évolution du cahier des charges	4
3	Jeux de données et prétraitement	5
3.1	Présentation des datasets	5
3.1.1	Dataset Cardiovascular Disease	5
3.1.2	Dataset Heart Disease	6
3.2	Analyse exploratoire	6
3.3	Prétraitement initial	7
3.4	Correction du data leakage sur Heart	7
3.5	Amélioration du contrôle qualité des données	8
3.6	Variables dérivées ajoutées	8
4	Modélisation et apprentissage automatique	10
4.1	Objectif de la modélisation	10
4.2	Algorithmes comparés	10
4.3	Métriques d'évaluation	11
4.4	Recherche d'hyperparamètres	11
4.5	Résultats sur le dataset Cardio	11
4.6	Validation croisée sur Cardio	12
4.7	Analyse des erreurs sur Cardio	12
4.8	Optimisation du seuil de décision sur Cardio	12
4.9	Résultats sur le dataset Heart	13
4.10	Optimisation du seuil de décision sur Heart	13
4.11	Interprétabilité des modèles	14
4.12	Visualisations des performances	14
5	Site web – Description fonctionnelle	16
5.1	Technologies utilisées	16
5.2	Architecture fonctionnelle	16
5.3	Page d'accueil	17
5.4	Page de prédiction	18
5.5	Calculateur d'IMC	19
5.6	Calculateur de besoins caloriques	20
5.7	Analyse de tension artérielle	20

5.8	Dashboard utilisateur	21
5.9	Historique	21
5.10	Page de connexion et inscription	22
5.11	Page de visualisations	23
5.12	Avertissement médical	23
6	Base de données SQL et espace utilisateur	24
6.1	Objectif de la base de données	24
6.2	Schéma relationnel	25
6.3	Description des tables	26
6.4	Connexion PHP à MySQL	26
6.5	Sécurité minimale	26
6.6	Intérêt pédagogique de la base SQL	27
7	Déploiement et contraintes techniques	28
7.1	Hébergement choisi	28
7.2	Contraintes liées à Python	28
7.3	Validation des modèles exportés	28
7.4	Vérifications réalisées	29
7.5	Documentation	29
8	Limites, bilan et perspectives	30
8.1	Bilan du projet	30
8.2	Limites méthodologiques	30
8.3	Difficultés rencontrées	31
8.4	Perspectives à long terme	31
8.5	Conclusion générale	31
A	Structure finale du projet	33
B	Extrait du schéma SQL	35
C	Tableau synthétique des améliorations réalisées	36

Table des figures

3.1	Distribution des classes dans les deux datasets	7
4.1	Interprétabilité des modèles retenus	14
4.2	Comparaison des performances des modèles sur les deux datasets	14
4.3	Matrices de confusion des modèles retenus	15
4.4	Courbes ROC des modèles comparés	15

5.1	Architecture fonctionnelle du flux de prédiction et de sauvegarde	16
5.2	Nouvelle page d'accueil de CardioPredict	17
5.3	Page de prédiction – mode classique	18
5.4	Nouvelle page de calcul d'IMC	19
5.5	Nouvelle page de calcul calorique	20
5.6	Dashboard utilisateur	21
5.7	Page de connexion de l'espace utilisateur	22
5.8	Page de visualisations du projet	23
6.1	Schéma relationnel simplifié de la base SQL	25

Liste des tableaux

2.1	Contribution synthétique par domaine de travail	4
3.1	Variables du dataset Cardio utilisées par le modèle	5
3.2	Variables du dataset Heart utilisées par le modèle	6
3.3	Tailles des ensembles d'apprentissage et de test	7
3.4	Contrôles de qualité ajoutés sur le dataset Cardio	8
4.1	Résultats améliorés sur le dataset Cardio	11
4.2	Matrice de confusion du meilleur modèle Cardio au seuil 0,5	12
4.3	Analyse des seuils sur le dataset Cardio	12
4.4	Résultats améliorés sur le dataset Heart avec classe malade évaluée explicitement .	13
4.5	Analyse des seuils sur le dataset Heart	13
6.1	Rôle des tables SQL ajoutées	26
C.1	Synthèse des améliorations intégrées à la version finale	36

Chapitre 1

Introduction

1.1 Contexte et motivation

Les maladies cardiovasculaires constituent un enjeu majeur de santé publique. Elles regroupent plusieurs pathologies touchant le coeur et les vaisseaux sanguins, parmi lesquelles l'hypertension artérielle, les accidents vasculaires cérébraux, les infarctus du myocarde ou encore certaines formes d'insuffisance cardiaque. Une partie importante du risque cardiovasculaire est liée à des facteurs mesurables ou observables : âge, pression artérielle, cholestérol, poids, activité physique, tabagisme, consommation d'alcool ou encore glycémie.

Dans ce contexte, les outils numériques peuvent jouer un rôle pédagogique utile. Ils ne remplacent pas un médecin, mais ils permettent à un utilisateur de mieux comprendre les facteurs associés au risque cardiovasculaire et d'être orienté vers une démarche de prévention. Le projet **CardioPredict** s'inscrit dans cette logique : proposer une interface accessible, claire et gratuite, capable d'estimer statistiquement un risque cardiovasculaire à partir de données simples.

1.2 Objectifs du projet

L'objectif initial était de construire une application complète combinant :

1. **Une partie data science** : choix de datasets pertinents, nettoyage, analyse exploratoire, entraînement de modèles et évaluation selon des métriques adaptées.
2. **Une partie web** : développement d'un site PHP permettant à l'utilisateur de remplir un formulaire et de recevoir un résultat compréhensible.
3. **Une partie déploiement** : mise en ligne du site et adaptation technique aux contraintes d'un hébergement mutualisé.

La version améliorée ajoute un quatrième objectif : transformer l'application en **plateforme de suivi santé pédagogique**. Cela signifie que l'utilisateur peut désormais créer un compte, conserver ses résultats, consulter un tableau de bord et utiliser plusieurs outils complémentaires liés à la prévention cardiovasculaire.

1.3 Valeur ajoutée de la version améliorée

La version finale du projet apporte une valeur ajoutée plus importante que la version initiale. Elle ne se contente plus de prédire un risque isolé ; elle permet aussi de contextualiser ce risque grâce à plusieurs indicateurs simples : IMC, tension artérielle, besoins caloriques et historique personnel.

Évolution principale du projet : CardioPredict passe d'un simple démonstrateur de machine learning à une application web structurée autour d'un espace utilisateur, d'une base SQL et d'outils de suivi santé.

Les principaux apports sont les suivants :

- intégration d'une base de données MySQL relationnelle ;
- création d'un espace utilisateur avec inscription, connexion et profil ;
- sauvegarde des prédictions et des calculs santé ;
- ajout d'un dashboard centralisant les résultats ;
- amélioration du site avec une navigation plus complète ;
- approfondissement de l'évaluation machine learning avec des métriques médicales.

1.4 Publics visés

Le site vise plusieurs profils d'utilisateurs :

- une personne souhaitant obtenir rapidement une estimation de son risque cardiovasculaire ;
- un étudiant ou enseignant souhaitant comprendre une application concrète de machine learning ;
- un utilisateur souhaitant conserver un historique personnel de ses indicateurs ;
- un jury universitaire évaluant la cohérence entre données, modèle, application et documentation.

Chapitre 2

Gestion de projet

2.1 Méthodologie de travail

Le projet a été conduit selon une logique itérative. La première version a permis de mettre en place le coeur du système : datasets, notebooks, modèles, formulaire de prédiction, visualisations et déploiement. Après évaluation, une deuxième phase d'amélioration a été engagée afin de renforcer les points faibles identifiés : base de données, espace utilisateur, historique, outils santé et rigueur méthodologique.

Cette organisation en deux temps a été bénéfique :

1. **Phase initiale** : obtenir un prototype fonctionnel complet.
2. **Phase d'amélioration** : transformer le prototype en application plus robuste, plus personnalisée et mieux documentée.

2.2 Outils utilisés

Les outils principaux utilisés sont :

- **GitHub** pour le dépôt du projet et la gestion des versions ;
- **Python** pour l'analyse de données, l'entraînement des modèles et les prédictions ;
- **pandas, scikit-learn, matplotlib, seaborn** pour les notebooks ;
- **PHP** pour la logique serveur et l'affichage web ;
- **MySQL/MariaDB** pour la base de données ;
- **PDO** pour les requêtes SQL préparées ;
- **HTML/CSS/JavaScript** pour l'interface utilisateur ;
- **MAMP** pour les tests locaux.

2.3 Répartition des contributions

La version initiale du projet reposait sur une répartition des tâches entre les membres du groupe. La phase d'amélioration a davantage porté sur le renforcement technique et fonctionnel du site : ajout de la base SQL, de l'espace utilisateur, des historiques et des outils santé.

TABLE 2.1 – Contribution synthétique par domaine de travail

Domaine	El Basri	Ali chedi	Ra- Bousquet	Beretti-P.
Sélection et analyse des datasets	Forte	Moyenne	Moyenne	Moyenne
Exploration et visualisations	Forte	Moyenne	Moyenne	Faible
Prétraitement et data leakage	Forte	Faible	Moyenne	Faible
Modélisation ML	Forte	Moyenne	Faible	Faible
Site web et intégration	Forte	Moyenne	Moyenne	Moyenne
Base SQL et espace utilisateur	Forte	Faible	Faible	Faible
Rapport et documentation	Forte	Moyenne	Faible	Faible

2.4 Évolution du cahier des charges

Les améliorations validées par l'enseignante ont été intégrées autour de quatre axes :

1. **Persistance des données** : ajout d'une base SQL et des historiques.
2. **Personnalisation** : comptes utilisateurs, sessions et dashboard.
3. **Prévention santé** : IMC, calories, tension artérielle.
4. **Rigueur machine learning** : métriques médicales, seuils, faux négatifs, hyperparamètres.

Chapitre 3

Jeux de données et prétraitement

3.1 Présentation des datasets

Deux jeux de données ont été utilisés afin de proposer deux niveaux de prédiction.

3.1.1 Dataset Cardiovascular Disease

Le dataset *Cardiovascular Disease* contient 70 000 observations. Il est adapté au **test classique**, car il repose sur des informations relativement simples : âge, genre, taille, poids, pression artérielle, cholestérol, glycémie, tabagisme, alcool et activité physique.

TABLE 3.1 – Variables du dataset Cardio utilisées par le modèle

Variable	Type	Exemple	Signification
age	numérique	18393	Âge en jours dans le dataset brut
gender	binaire	1/2	Genre, 1=femme et 2=homme
height	numérique	170	Taille en centimètres
weight	numérique	70.0	Poids en kilogrammes
ap_hi	numérique	120	Pression systolique
ap_lo	numérique	80	Pression diastolique
cholesterol	ordinal	1–3	Niveau de cholestérol
gluc	ordinal	1–3	Niveau de glucose
smoke	binaire	0/1	Tabagisme
alco	binaire	0/1	Consommation d'alcool
active	binaire	0/1	Activité physique régulière
cardio	binaire	0/1	Variable cible : 1 = maladie cardiovasculaire

3.1.2 Dataset Heart Disease

Le dataset *Heart Disease* contient initialement 1 025 lignes. Après suppression des doublons, il reste 302 observations uniques. Il est utilisé pour le **test avancé**, car les variables sont plus cliniques : douleur thoracique, ECG, fréquence cardiaque maximale, oldpeak, pente du segment ST, nombre de vaisseaux colorés, etc.

Point méthodologique important : dans le pipeline final du projet, le dataset Heart a été traité avec la convention suivante : **target=0** correspond à la classe malade et **target=1** à la classe saine. Le script de production inverse donc la probabilité retournée par le modèle afin d’afficher une probabilité de maladie cohérente pour l’utilisateur.

TABLE 3.2 – Variables du dataset Heart utilisées par le modèle

Variable	Type	Valeurs	Signification
age	numérique	29–77	Âge en années
sex	binaire	0/1	Sexe
cp	ordinal	0–3	Type de douleur thoracique
trestbps	numérique	94–200	Pression artérielle au repos
chol	numérique	126–564	Cholestérol sérique
fbs	binaire	0/1	Glycémie à jeun supérieure à 120 mg/dL
restecg	ordinal	0–2	Résultat ECG au repos
thalach	numérique	71–202	Fréquence cardiaque maximale
exang	binaire	0/1	Angine induite par l’effort
oldpeak	numérique	0–6.2	Dépression du segment ST
slope	ordinal	0–2	Pente du segment ST
ca	ordinal	0–4	Nombre de vaisseaux colorés
thal	ordinal	0–3	Résultat au test thallium
target	binaire	0/1	Dans le pipeline final : 0 = malade, 1 = sain

3.2 Analyse exploratoire

La distribution de la variable cible a été vérifiée pour les deux datasets. Cette étape est essentielle car un déséquilibre trop fort pourrait biaiser le modèle vers la classe majoritaire.




FIGURE 3.1 – Distribution des classes dans les deux datasets

Le dataset Cardio est presque parfaitement équilibré : 35 021 observations sans maladie cardiovasculaire et 34 979 avec maladie cardiovasculaire. Le dataset Heart, après déduplication, contient 164 observations de classe 1 et 138 observations de classe 0. Aucun rééquilibrage artificiel de type SMOTE n’a donc été nécessaire.

3.3 Prétraitement initial

Les étapes initiales de prétraitement sont les suivantes :

- suppression des colonnes d’identifiant inutiles pour la modélisation ;
- conversion des décimales lorsque certaines valeurs utilisent la virgule ;
- transformation de l’âge en années côté interface pour le dataset Cardio ;
- imputation des valeurs manquantes par la médiane ;
- standardisation des variables numériques ;
- split train/test 80/20 stratifié avec graine aléatoire fixée à 42.

TABLE 3.3 – Tailles des ensembles d’apprentissage et de test

Dataset	Total	Train 80%	Test 20%
Cardio	70 000	56 000	14 000
Heart	302	241	61

3.4 Correction du data leakage sur Heart

Un point critique du projet a été la détection d’un risque de *data leakage* sur le dataset Heart. Le fichier brut contient 1 025 lignes, mais 723 d’entre elles sont des doublons. Sans suppression de ces doublons, une même observation peut se retrouver à la fois dans l’ensemble d’entraînement et dans l’ensemble de test, ce qui gonfle artificiellement les performances.

La correction appliquée est la suivante :

1. suppression des colonnes techniques non prédictives ;
2. conversion des formats numériques ;
3. déduplication complète des observations ;
4. vérification de l'absence de chevauchement entre train et test.

Après correction, le dataset passe de 1 025 lignes à 302 observations uniques. Cette étape est l'une des plus importantes du projet, car elle garantit que les performances mesurent une vraie capacité de généralisation.

3.5 Amélioration du contrôle qualité des données

La version améliorée ajoute une analyse plus précise des valeurs aberrantes, en particulier pour le dataset Cardio. Certaines valeurs brutes sont médicalement impossibles ou très peu plausibles : pression systolique négative, pression diastolique extrême, taille trop faible, poids incohérent ou pression systolique inférieure à la pression diastolique.

TABLE 3.4 – Contrôles de qualité ajoutés sur le dataset Cardio

Contrôle	Nombre de lignes concernées
<code>ap_hi < ap_lo</code>	1 234
<code>ap_hi</code> hors intervalle 80–240	247
<code>ap_lo</code> hors intervalle 40–160	1 025
Taille hors intervalle 120–220 cm	53
Poids hors intervalle 35–200 kg	20
IMC hors intervalle 12–60	74

Un filtrage combiné des valeurs incohérentes conserverait 68 598 lignes et supprimerait 1 402 observations, soit environ 2% du dataset. Ce résultat est intéressant : la majorité des données est exploitable, mais la présence d'un petit nombre d'observations aberrantes justifie une analyse explicite avant la modélisation.

3.6 Variables dérivées ajoutées

La version améliorée enrichit l'analyse avec trois variables dérivées utiles :

$$\text{IMC} = \frac{\text{poids}}{(\text{taille en mètres})^2}$$

$$\text{Pression pulsée} = \text{pression systolique} - \text{pression diastolique}$$

$$\text{Pression artérielle moyenne} = \text{pression diastolique} + \frac{\text{pression systolique} - \text{pression diastolique}}{3}$$

Ces variables ne servent pas uniquement à améliorer le notebook : elles établissent aussi un lien direct avec les nouvelles pages du site, notamment les calculateurs IMC et tension.

Chapitre 4

Modélisation et apprentissage automatique

4.1 Objectif de la modélisation

Le but de la modélisation est de construire un classifieur capable de distinguer les profils associés à un risque cardiovasculaire des profils non associés à ce risque. Les deux datasets donnent lieu à deux modèles distincts, car les variables disponibles ne sont pas les mêmes.

- **Dataset Cardio** : modèle grand public, basé sur des variables générales.
- **Dataset Heart** : modèle clinique, basé sur des variables médicales plus précises.

4.2 Algorithmes comparés

La version initiale comparait trois modèles : régression logistique, arbre de décision et forêt aléatoire. La version améliorée conserve cette base et ajoute une recherche d'hyperparamètres ciblée sur les modèles les plus pertinents.

Les modèles considérés sont :

- **Régression logistique** : modèle linéaire interprétable, particulièrement adapté au petit dataset Heart.
- **Arbre de décision** : modèle non linéaire facile à interpréter, mais plus sensible au surapprentissage.
- **Forêt aléatoire** : méthode d'ensemble robuste, bien adaptée au dataset Cardio grâce au grand nombre d'observations.
- **Versions optimisées** : recherche d'hyperparamètres par `RandomizedSearchCV` pour améliorer la robustesse.

4.3 Métriques d'évaluation

La métrique principale reste la **ROC-AUC**, car elle mesure la capacité du modèle à classer correctement les individus à risque indépendamment du seuil de décision. Cependant, la version améliorée ajoute des métriques plus adaptées à un contexte de santé :

- **rappel** : proportion de malades correctement détectés ;
- **spécificité** : proportion de non-malades correctement classés ;
- **faux négatifs** : malades classés comme non-malades ;
- **faux positifs** : non-malades classés comme malades ;
- **PR-AUC** : aire sous la courbe précision-rappel ;
- **balanced accuracy** : moyenne entre rappel et spécificité.

En santé, les faux négatifs sont particulièrement importants : un faux négatif correspond à un patient potentiellement malade que le modèle classe comme non malade. C'est pourquoi l'analyse ne doit pas se limiter à l'accuracy.

4.4 Recherche d'hyperparamètres

Une recherche d'hyperparamètres ciblée a été ajoutée afin d'améliorer la robustesse des modèles. Pour le dataset Cardio, la meilleure configuration de forêt aléatoire obtient une ROC-AUC moyenne en validation croisée de 0,8024. Les paramètres retenus sont notamment : 150 arbres, profondeur maximale 10, `min_samples_split=10`, `min_samples_leaf=4` et `class_weight=balanced`.

Pour le dataset Heart, la meilleure régression logistique obtient une ROC-AUC de validation croisée de 0,9131, avec une régularisation `C=0.1`. Ce résultat confirme qu'un modèle simple et régularisé peut mieux généraliser sur un dataset de petite taille.

4.5 Résultats sur le dataset Cardio

TABLE 4.1 – Résultats améliorés sur le dataset Cardio

Modèle	Acc.	Bal. acc.	Préc.	Rappel	F1	ROC-AUC
Random Forest optimisé	0,7333	0,7333	0,7597	0,6820	0,7187	0,7987
Random Forest initial	0,7319	0,7318	0,7561	0,6841	0,7183	0,7983
Arbre de décision	0,7276	0,7275	0,7569	0,6700	0,7108	0,7899
Régression logistique	0,7136	0,7136	0,7314	0,6748	0,7020	0,7781

La forêt aléatoire reste le meilleur choix pour le dataset Cardio. L'optimisation apporte un gain modéré, mais confirme la stabilité du modèle. La ROC-AUC est proche de 0,80, ce qui signifie que le modèle a une capacité de discrimination nettement supérieure à un classifieur aléatoire.

4.6 Validation croisée sur Cardio

La validation croisée à 5 plis donne les scores ROC-AUC suivants : 0,8001 ; 0,8005 ; 0,8044 ; 0,8019 ; 0,8062. La moyenne est de 0,8026 avec un écart-type de 0,0026 et un intervalle de confiance à 95% approximatif de [0,8003 ; 0,8049].

Cette faible dispersion montre que la performance du modèle Cardio est stable et ne dépend pas fortement d'un seul découpage train/test.

4.7 Analyse des erreurs sur Cardio

Pour le meilleur modèle Cardio au seuil 0,5, la matrice de confusion est la suivante :

TABLE 4.2 – Matrice de confusion du meilleur modèle Cardio au seuil 0,5

	Prédit sain	Prédit malade
Réel sain	5 495	1 509
Réel malade	2 225	4 771

Le modèle détecte 4 771 vrais positifs, mais laisse encore 2 225 faux négatifs. Cette analyse justifie l'étude du seuil de décision.

4.8 Optimisation du seuil de décision sur Cardio

Le seuil classique de 0,5 n'est pas nécessairement optimal en contexte médical. La version améliorée teste plusieurs seuils afin d'observer le compromis entre rappel et spécificité.

TABLE 4.3 – Analyse des seuils sur le dataset Cardio

Seuil	Précision	Rappel	Spécificité	Faux négatifs	Faux positifs
0,30	0,6309	0,8796	0,4859	842	3 601
0,35	0,6580	0,8415	0,5631	1 109	3 060
0,40	0,6972	0,7854	0,6593	1 501	2 386
0,45	0,7319	0,7367	0,7304	1 842	1 888
0,50	0,7597	0,6820	0,7846	2 225	1 509

Un seuil de 0,30 réduit les faux négatifs de 2 225 à 842, mais augmente fortement les faux positifs. Cette observation montre qu'un outil médical ne doit pas choisir son seuil uniquement par défaut : il doit expliciter le compromis entre ne pas manquer des patients à risque et ne pas alerter inutilement des patients non à risque.

4.9 Résultats sur le dataset Heart

Le dataset Heart étant beaucoup plus petit, les résultats doivent être interprétés avec prudence. La régression logistique reste le modèle le plus adapté.

TABLE 4.4 – Résultats améliorés sur le dataset Heart avec classe malade évaluée explicitement

Modèle	Acc.	Bal. acc.	Préc.	Rappel	F1	ROC-AUC
Régression logistique optimisée	0,7869	0,7814	0,8000	0,7143	0,7547	0,8810
Régression logistique initiale	0,8033	0,7992	0,8077	0,7500	0,7778	0,8712
Random Forest	0,7705	0,7689	0,7500	0,7500	0,7500	0,8615
Arbre de décision	0,7705	0,7716	0,7333	0,7857	0,7586	0,8317

La régression logistique optimisée présente la meilleure ROC-AUC, mais la régression logistique initiale garde une accuracy et un F1-score légèrement supérieurs. La différence s'explique par la petite taille du test set : seulement 61 observations. Le rapport final présente donc les deux lectures au lieu de masquer cette instabilité.

4.10 Optimisation du seuil de décision sur Heart

TABLE 4.5 – Analyse des seuils sur le dataset Heart

Seuil	Précision	Rappel	Spécificité	Faux négatifs	Faux positifs
0,30	0,6190	0,9286	0,5152	2	16
0,35	0,6579	0,8929	0,6061	3	13
0,40	0,7500	0,8571	0,7576	4	8
0,45	0,7500	0,7500	0,7879	7	7
0,50	0,8000	0,7143	0,8485	8	5

Ici encore, abaisser le seuil améliore le rappel. Par exemple, le seuil 0,40 réduit les faux négatifs de 8 à 4 tout en conservant une spécificité de 0,7576. Cette analyse est plus adaptée au contexte médical que le simple affichage de l'accuracy.

4.11 Interprétabilité des modèles




FIGURE 4.1 – Interprétabilité des modèles retenus

Pour le dataset Cardio, la pression systolique, l’âge et le poids apparaissent parmi les variables les plus influentes. Pour le dataset Heart, les variables cliniques comme la douleur thoracique, le nombre de vaisseaux colorés, la fréquence cardiaque maximale ou les indicateurs ECG jouent un rôle important.

La version améliorée ajoute aussi une interprétabilité par **permutation importance**. Cette méthode mesure la baisse de performance lorsque l’on mélange aléatoirement une variable. Elle complète l’importance Gini de la forêt aléatoire, qui peut parfois favoriser certaines variables numériques.

4.12 Visualisations des performances






FIGURE 4.2 – Comparaison des performances des modèles sur les deux datasets




(a) Matrice de confusion Cardio




(b) Matrice de confusion Heart

FIGURE 4.3 – Matrices de confusion des modèles retenus



(a) ROC – Cardio



(b) ROC – Heart

FIGURE 4.4 – Courbes ROC des modèles comparés

Chapitre 5

Site web – Description fonctionnelle

5.1 Technologies utilisées

Le site web combine plusieurs technologies :

- **PHP** pour la logique serveur, les formulaires, les sessions et l'appel du script Python ;
- **Python standard** pour la prédiction en production ;
- **JSON** pour l'échange entre PHP et Python ;
- **MySQL** pour les comptes utilisateurs et les historiques ;
- **HTML/CSS/JavaScript** pour l'interface ;
- **PDO** pour une connexion SQL plus sécurisée.

5.2 Architecture fonctionnelle

Le flux de prédiction reste proche de la version initiale, mais il a été renforcé par l'ajout de la base de données.




FIGURE 5.1 – Architecture fonctionnelle du flux de prédiction et de sauvegarde

Lorsqu'un utilisateur réalise une prédiction :

1. le formulaire PHP reçoit les données ;
2. un fichier JSON temporaire unique est créé avec `uniqid()` ;
3. PHP appelle `ml/predict.py` via `shell_exec()` ;
4. Python charge le modèle JSON et renvoie la probabilité ;
5. PHP affiche le résultat ;
6. si la base SQL est disponible, la prédiction est enregistrée dans `prediction_history` ;
7. le fichier temporaire est supprimé après l'exécution.

5.3 Page d'accueil




FIGURE 5.2 – Nouvelle page d'accueil de CardioPredict

La page d'accueil a été modernisée. Elle présente plus clairement la finalité du projet : évaluer le risque cardiovasculaire avec des données simples, tout en proposant une interface pédagogique autour de la prévention. Elle met en avant le nombre d'observations exploitées, les deux tests disponibles et la meilleure ROC-AUC observée.

5.4 Page de prédiction


FIGURE 5.3 – Page de prédiction – mode classique

La page de prédiction conserve les deux modes :

- **Test classique** : données générales accessibles à tous ;
- **Test avancé** : données cliniques issues d'un bilan médical.

Le résultat affiche la probabilité estimée, le niveau de risque, le modèle utilisé et les métriques principales. Cette page a aussi été modifiée pour enregistrer les prédictions dans la base lorsque l'utilisateur est connecté, tout en restant utilisable sans compte.

5.5 Calculateur d'IMC



The screenshot shows the 'Calculateur IMC' (IMC Calculator) page of the CardioPredict application. The page has a light blue background and a white content area. At the top, there is a navigation bar with the CardioPredict logo and several menu items: Accueil, Prediction, IMC (highlighted), Calories, Tension, Dashboard, Historique, Visualisations, Methode, and Connexion. Below the navigation bar, the main heading 'Calculateur IMC' is displayed, followed by a subtitle: 'Calcule ton indice de masse corporelle à partir de ton poids et de ta taille.' The interface is divided into two main sections. The left section, titled 'Calculer mon IMC', contains two input fields: 'Poids (kg)' and 'Taille (cm)', both with light blue borders and placeholder text. Below these fields is a dark blue button labeled 'Calculer l'IMC'. The right section, titled 'Resultat', contains a light blue box with the text: 'Aucun calcul pour le moment. Renseigne ton poids et ta taille pour obtenir une estimation.' At the bottom of the page, there is a small disclaimer: 'Cette application est un outil pédagogique universitaire. Les résultats fournis sont des estimations statistiques et ne remplacent pas un diagnostic médical. En cas de doute, consultez un professionnel de santé.'

FIGURE 5.4 – Nouvelle page de calcul d'IMC

La page `imc.php` calcule l'indice de masse corporelle à partir du poids et de la taille. Le résultat est classé en quatre catégories : insuffisance pondérale, poids normal, surpoids ou obésité. Si la base est disponible, le calcul est sauvegardé dans `bmi_history`.

Cette page fait le lien entre le modèle Cardio et un indicateur de santé compréhensible par le grand public.

5.6 Calculateur de besoins caloriques

FIGURE 5.5 – Nouvelle page de calcul calorique

La page `calories.php` estime le métabolisme de base et les besoins caloriques journaliers. Elle utilise la formule de Mifflin-St Jeor :

$$\text{Homme : } BMR = 10 \times \text{poids} + 6,25 \times \text{taille} - 5 \times \text{âge} + 5$$

$$\text{Femme : } BMR = 10 \times \text{poids} + 6,25 \times \text{taille} - 5 \times \text{âge} - 161$$

Le résultat est ensuite multiplié par un facteur d'activité : sédentaire, activité légère, activité modérée ou activité intense. Cette fonctionnalité complète l'approche préventive du projet.

5.7 Analyse de tension artérielle

La page `tension.php` permet de saisir une pression systolique et une pression diastolique. Elle calcule deux indicateurs :

$$\text{Pression pulsée} = ap_hi - ap_lo$$

$$\text{Pression artérielle moyenne} = ap_lo + \frac{ap_hi - ap_lo}{3}$$

Elle classe ensuite la mesure en catégories simples : normale, élevée, hypertension possible ou

valeur incohérente. Ce module est cohérent avec le dataset Cardio, où la pression artérielle est l'une des variables les plus importantes.

5.8 Dashboard utilisateur




FIGURE 5.6 – Dashboard utilisateur


La page `dashboard.php` devient la page centrale de l'espace personnel. Si l'utilisateur n'est pas connecté, elle l'invite à créer un compte. S'il est connecté, elle affiche :

- le nombre total de prédictions ;
- la dernière prédiction ;
- le dernier IMC ;
- la dernière tension ;
- le dernier calcul calorique ;
- des liens rapides vers les outils du site.

5.9 Historique

La page `historique.php` affiche les résultats sauvegardés pour l'utilisateur connecté : prédictions, IMC, calories et tension. Elle ne mélange pas les utilisateurs : chaque requête SQL filtre les données avec `user_id`. Si l'utilisateur n'est pas connecté, un message l'invite à se connecter.

5.10 Page de connexion et inscription



The screenshot shows the 'Connexion' (Login) page of the CardioPredict application. At the top, there is a navigation bar with the 'CP CardioPredict' logo and several menu items: Accueil, Prediction, IMC, Calories, Tension, Dashboard, Historique, Visualisations, Methode, and Connexion (which is highlighted). The main content area is titled 'Connexion' and includes a sub-header: 'Connecte-toi pour sauvegarder automatiquement les predictions et les calculs sante.' Below this, there are two main sections. The left section, 'Se connecter', contains input fields for 'Email' and 'Mot de passe', followed by a 'Connexion' button. The right section, 'Pas encore de compte ?', includes a brief description: 'L'inscription permet de conserver un historique personnel des predictions et outils sante.', and a 'Creer un compte' button. At the bottom of the page, there is a footer box with the text: 'CardioPredict - Projet universitaire de machine learning appliqué à la santé. Interface web de démonstration avec visualisations et prédiction cardiovasculaire.'

FIGURE 5.7 – Page de connexion de l'espace utilisateur

L'espace utilisateur repose sur quatre pages :

- `register.php` : création de compte ;
- `login.php` : connexion ;
- `logout.php` : déconnexion ;
- `profile.php` : consultation du profil.

Les mots de passe sont hachés avec `password_hash()` et vérifiés avec `password_verify()`. Les requêtes SQL utilisent des requêtes préparées PDO.

5.11 Page de visualisations




FIGURE 5.8 – Page de visualisations du projet

La page de visualisations regroupe les graphiques issus de l'analyse exploratoire et de l'évaluation des modèles. Elle est organisée en onglets : dataset Cardio, dataset Heart et comparaison des modèles. Chaque graphique est accompagné d'une interprétation afin de rendre le projet plus pédagogique.

5.12 Avertissement médical

Un avertissement médical a été ajouté sur les pages sensibles : prédiction, IMC, calories et tension. Il rappelle que l'application est un outil pédagogique universitaire et que les résultats sont des estimations statistiques ne remplaçant pas un diagnostic médical.

Chapitre 6

Base de données SQL et espace utilisateur

6.1 Objectif de la base de données

La base SQL constitue l'une des améliorations les plus importantes du projet. Dans la version initiale, le site permettait de réaliser une prédiction mais ne conservait pas les résultats. La version finale ajoute une base relationnelle permettant de stocker :

- les comptes utilisateurs ;
- les prédictions cardiovasculaires ;
- les calculs d'IMC ;
- les estimations caloriques ;
- les analyses de tension artérielle.

Cette évolution transforme le site en application de suivi personnel.

6.2 Schéma relationnel




FIGURE 6.1 – Schéma relationnel simplifié de la base SQL

Le schéma repose sur une table centrale **users**, reliée à quatre tables d'historique. Les clés étrangères utilisent **ON DELETE SET NULL**. Ainsi, si un utilisateur est supprimé, ses historiques peuvent être conservés sous forme anonymisée.

6.3 Description des tables

TABLE 6.1 – Rôle des tables SQL ajoutées

Table	Rôle
<code>users</code>	Stocke les comptes utilisateurs : identifiant, nom, email, mot de passe haché, date de création.
<code>prediction_history</code>	Stocke les prédictions cardiovasculaires, le mode utilisé, le modèle, la probabilité, le niveau de risque et certaines données saisies.
<code>bmi_history</code>	Stocke les calculs d'IMC et leur catégorie.
<code>calorie_history</code>	Stocke les estimations du métabolisme de base et des besoins caloriques.
<code>blood_pressure_history</code>	Stocke les mesures de tension, la pression pulsée, la pression artérielle moyenne et la catégorie associée.

6.4 Connexion PHP à MySQL

La connexion à la base est centralisée dans `site/config/db.php`. Ce fichier définit deux fonctions :

- `getDatabaseConnection()` : connexion obligatoire à la base ;
- `getOptionalDatabaseConnection()` : connexion optionnelle permettant de ne pas bloquer la prédiction si la base est indisponible.

Cette deuxième fonction est particulièrement importante : elle garantit que le coeur du projet, c'est-à-dire la prédiction ML, reste disponible même si MySQL rencontre un problème. Dans ce cas, seule la sauvegarde de l'historique est ignorée.

6.5 Sécurité minimale

Plusieurs pratiques de sécurité ont été ajoutées :

- mots de passe hachés avec `password_hash()` ;
- vérification de mot de passe avec `password_verify()` ;
- utilisation de sessions PHP ;
- requêtes SQL préparées ;
- filtrage par `user_id` pour les historiques ;
- absence d'affichage des erreurs SQL détaillées à l'utilisateur ;
- sauvegarde optionnelle si la base n'est pas disponible.

Pour une mise en production réelle, il faudrait en plus déplacer les identifiants MySQL vers des variables d'environnement ou un fichier de configuration non versionné. Le rapport ne doit pas exposer de mot de passe ou d'identifiant sensible.

6.6 Intérêt pédagogique de la base SQL

Cette base de données améliore fortement la cohérence du projet :

- elle relie la partie web à une vraie persistance des données ;
- elle permet de démontrer des compétences en modélisation relationnelle ;
- elle rend possible l'espace utilisateur ;
- elle permet un suivi longitudinal des résultats ;
- elle prépare des améliorations futures, comme un export PDF ou une API.

Chapitre 7

Déploiement et contraintes techniques

7.1 Hébergement choisi

Le site a été conçu pour fonctionner localement avec MAMP et pour être déployé sur un hébergement PHP. La première version a été déployée sur IONOS avec le nom de domaine <http://cardio-predict.fr>. Le choix de PHP facilite l'hébergement sur des offres mutualisées, mais impose certaines contraintes sur l'exécution Python.

7.2 Contraintes liées à Python

Sur un hébergement mutualisé, l'installation de bibliothèques Python comme `numpy`, `pandas` ou `scikit-learn` peut être limitée. Pour contourner cette difficulté, les modèles entraînés localement sont exportés en JSON, puis réimplémentés en Python standard dans `ml/predict.py`.

Cette solution présente plusieurs avantages :

- aucune dépendance externe nécessaire en production ;
- déploiement plus simple ;
- contrôle complet du calcul de probabilité ;
- meilleure compatibilité avec les hébergements mutualisés.

7.3 Validation des modèles exportés

Les modèles JSON ont été comparés aux modèles d'origine afin de vérifier que l'export ne modifie pas les prédictions. Les résultats de validation de la version initiale indiquaient :

- forêt aléatoire Cardio : 500/500 prédictions identiques ;
- régression logistique Heart : 302/302 prédictions identiques ;
- différence maximale de probabilité inférieure à 0,007, due aux arrondis flottants.

La version améliorée conserve ce principe et ajoute une meilleure gestion des fichiers temporaires : chaque prédiction utilise désormais un nom unique grâce à `uniqid()`, puis supprime le fichier après exécution.

7.4 Vérifications réalisées

Plusieurs vérifications ont été effectuées après les modifications :

- vérification syntaxique PHP avec `php -l` sur les pages principales ;
- test de chargement HTTP des pages principales ;
- vérification que la prédiction reste utilisable sans base SQL ;
- vérification du fonctionnement Python avec le lanceur Windows `py.exe -3.11` ;
- vérification que les notebooks restent des fichiers JSON valides ;
- contrôle syntaxique des cellules Python avec `ast.parse` ;
- test de la logique des métriques médicales ;
- test des nouvelles variables d’exploration : pression pulsée et pression artérielle moyenne.

7.5 Documentation

Le fichier `README.md` a été mis à jour afin de documenter :

- l’installation avec MAMP ;
- la création de la base SQL ;
- l’import du fichier `database/schema.sql` ;
- la configuration de `site/config/db.php` ;
- le flux de prédiction ;
- le flux utilisateur ;
- les nouvelles pages ;
- les limites médicales du projet.

Un second fichier, `database/README_database.md`, explique le rôle des tables et la procédure d’import.

Chapitre 8

Limites, bilan et perspectives

8.1 Bilan du projet

CardioPredict couvre désormais l'ensemble du cycle d'un projet de science des données appliqué :

- sélection et compréhension de datasets réels ;
- nettoyage, déduplication et contrôle de qualité ;
- modélisation supervisée ;
- évaluation par métriques classiques et médicales ;
- interprétabilité des modèles ;
- développement d'un site web ;
- intégration de modèles ML dans une application PHP/Python ;
- ajout d'une base SQL ;
- création d'un espace utilisateur et d'un dashboard ;
- documentation et déploiement.

La version améliorée est plus cohérente que la version initiale car elle relie les dimensions data science, web, base de données et santé numérique.

8.2 Limites méthodologiques

Malgré les améliorations, plusieurs limites doivent être rappelées :

- les datasets proviennent de sources publiques et ne constituent pas une cohorte médicale validée pour un usage clinique ;
- le dataset Heart est très petit après déduplication, ce qui rend les métriques sensibles au découpage ;
- certaines variables importantes sont absentes : antécédents familiaux, traitements, alimentation détaillée, niveau précis d'activité physique ;

- le modèle donne une estimation statistique, pas un diagnostic médical ;
- les seuils de décision doivent être interprétés avec prudence ;
- les outils IMC, calories et tension sont pédagogiques et simplifiés.

8.3 Difficultés rencontrées

Les principales difficultés ont été :

- la détection du data leakage sur Heart ;
- la gestion de l'âge en jours dans le dataset Cardio ;
- l'export des modèles en JSON pour contourner les limites d'hébergement ;
- la cohérence du codage de la variable cible Heart ;
- l'intégration d'une base SQL sans casser le flux de prédiction existant ;
- la conservation du fonctionnement sans compte tout en ajoutant un historique pour les utilisateurs connectés.

8.4 Perspectives à long terme

Les perspectives les plus intéressantes sont :

- ajout d'un export PDF des résultats utilisateur ;
- ajout de graphiques d'évolution personnelle dans le dashboard ;
- calibration des probabilités ;
- ajout d'une API REST ;
- gestion plus avancée des comptes utilisateurs ;
- stockage anonymisé pour analyses statistiques globales ;
- amélioration des modèles avec davantage de données médicales ;
- validation externe sur un dataset indépendant.

8.5 Conclusion générale

Le projet CardioPredict montre comment un projet universitaire peut articuler machine learning, développement web, base de données et prévention santé. La première version démontrait déjà la faisabilité technique d'une prédiction cardiovasculaire accessible depuis un site web. La version améliorée renforce nettement le projet en ajoutant un espace personnel, un historique, une base SQL, des outils santé et une évaluation machine learning plus adaptée au contexte médical.

Le résultat final est une application plus professionnelle, plus explicable et plus complète. Elle respecte la contrainte essentielle du domaine médical : informer et sensibiliser sans se substituer à un professionnel de santé.

Bibliographie

- [1] Sulianova. *Cardiovascular Disease Dataset*. Kaggle, 2019. URL : <https://www.kaggle.com/datasets/sulianova/cardiovascular-disease-dataset>
- [2] johnsmith88. *Heart Disease Dataset*. Kaggle, 2019. URL : <https://www.kaggle.com/datasets/johnsmith88/heart-disease-dataset>
- [3] Janosi, A., Steinbrunn, W., Pfisterer, M., Detrano, R. *Heart Disease Data Set*. UCI Machine Learning Repository, 1988.
- [4] Breiman, L. *Random Forests*. Machine Learning, 45(1), 5–32, 2001.
- [5] Hosmer, D.W., Lemeshow, S. *Applied Logistic Regression*. Wiley, 2000.
- [6] Fawcett, T. *An Introduction to ROC Analysis*. Pattern Recognition Letters, 27(8), 861–874, 2006.

Chapitre A

Structure finale du projet

```
projet-ml-cardiovasculaire/  
|-- README.md  
|-- database/  
|   |-- schema.sql  
|   |-- README_database.md  
|-- notebooks/  
|   |-- 01_exploration_visualisation.ipynb  
|   |-- 02_modelisation_prediction.ipynb  
|   |-- cardio.csv  
|   |-- heart.csv  
|-- rapport/  
|   |-- le_rapport.pdf  
|   |-- modifications_a_integrer.md  
|-- site/  
|   |-- index.php  
|   |-- prediction.php  
|   |-- register.php  
|   |-- login.php  
|   |-- logout.php  
|   |-- profile.php  
|   |-- dashboard.php  
|   |-- historique.php  
|   |-- imc.php  
|   |-- calories.php  
|   |-- tension.php  
|   |-- visualisations.php  
|   |-- methode.php  
|   |-- partials_header.php  
|   |-- partials_footer.php  
|   |-- config/db.php  
|   |-- assets/css/style.css  
|   |-- assets/js/app.js  
|   |-- assets/img/  
|   |-- data/cardio.csv
```

```
| |-- data/heart.csv
| |-- ml/predict.py
| |-- ml/models/cardio_model.json
| |-- ml/models/heart_model.json
| |-- ml/metadata/cardio_model_info.json
| |-- ml/metadata/heart_model_info.json
| |-- tmp/
```

Chapitre B

Extrait du schéma SQL

```
CREATE TABLE users (  
    id INT UNSIGNED NOT NULL AUTO_INCREMENT,  
    username VARCHAR(80) NOT NULL,  
    email VARCHAR(190) NOT NULL,  
    password_hash VARCHAR(255) NOT NULL,  
    created_at DATETIME NOT NULL DEFAULT CURRENT_TIMESTAMP,  
    PRIMARY KEY (id),  
    UNIQUE KEY uq_users_username (username),  
    UNIQUE KEY uq_users_email (email)  
) ENGINE=InnoDB DEFAULT CHARSET=utf8mb4 COLLATE=utf8mb4_unicode_ci;  
  
CREATE TABLE prediction_history (  
    id INT UNSIGNED NOT NULL AUTO_INCREMENT,  
    user_id INT UNSIGNED NULL,  
    created_at DATETIME NOT NULL DEFAULT CURRENT_TIMESTAMP,  
    mode VARCHAR(20) NOT NULL,  
    model_name VARCHAR(120) NULL,  
    probability DECIMAL(6,5) NULL,  
    risk_label VARCHAR(80) NULL,  
    prediction_label VARCHAR(160) NULL,  
    age DECIMAL(5,1) NULL,  
    gender VARCHAR(30) NULL,  
    weight DECIMAL(6,2) NULL,  
    height DECIMAL(6,2) NULL,  
    ap_hi INT NULL,  
    ap_lo INT NULL,  
    cholesterol TINYINT NULL,  
    gluc TINYINT NULL,  
    PRIMARY KEY (id),  
    KEY idx_prediction_history_user_created (user_id, created_at),  
    CONSTRAINT fk_prediction_history_user  
        FOREIGN KEY (user_id) REFERENCES users(id)  
        ON DELETE SET NULL  
) ENGINE=InnoDB DEFAULT CHARSET=utf8mb4 COLLATE=utf8mb4_unicode_ci;
```


Chapitre C

Tableau synthétique des améliorations réalisées

TABLE C.1 – Synthèse des améliorations intégrées à la version finale

Axe	Améliorations réalisées
Base SQL	Création de <code>database/schema.sql</code> , tables <code>users</code> , <code>prediction_history</code> , <code>bmi_history</code> , <code>calorie_history</code> , <code>blood_pressure_history</code> , clés étrangères et encodage <code>utf8mb4</code> .
Connexion MySQL	Ajout de <code>site/config/db.php</code> , connexion PDO, fonction optionnelle pour ne pas bloquer le site si MySQL est indisponible.
Espace utilisateur	Ajout de <code>register.php</code> , <code>login.php</code> , <code>logout.php</code> , <code>profile.php</code> , sessions, mots de passe hachés et requêtes préparées.
Historique	Modification de <code>prediction.php</code> , ajout de <code>historique.php</code> , sauvegarde des prédictions et calculs associés à <code>user_id</code> .
Outils santé	Ajout des pages <code>imc.php</code> , <code>calories.php</code> , <code>tension.php</code> avec sauvegarde dans la base.
Dashboard	Ajout de <code>dashboard.php</code> , affichage des derniers résultats et liens rapides vers les fonctionnalités principales.
Navigation	Mise à jour de <code>partials_header.php</code> pour intégrer les nouvelles pages et la connexion/déconnexion.
Avertissement médical	Ajout d'un message pédagogique sur les pages de prédiction et d'outils santé.
Exploration	Ajout de variables dérivées, détection d'outliers, contrôle <code>ap_hi < ap_lo</code> , tensions extrêmes, IMC incohérents.
Modélisation	Ajout de métriques médicales, PR-AUC, balanced accuracy, faux négatifs, faux positifs, recherche d'hyperparamètres, seuils de décision et permutation importance.

Axe	Améliorations réalisées
Design	Modernisation de l'interface, header plus compact, cartes plus lisibles, dashboard et historique plus professionnels.
Documentation	Mise à jour du README.md et création de database/README_database.md.
